

浅谈EM算法

—— fangz_z

EM算法也是一个非常常见的算法了，它可以通过迭代为很多没有解析解的问题提供一个局部最优解，在很多模型中都有应用。仔细梳理一下算法的思路流程，就发现这个算法其实还是很容易掌握的。

算法描述

考虑一个带隐变量的模型，观测数据集为 X ，潜在变量集合为 Z ，参数为 θ ，则可以写出它的对数似然函数：

$$\ln p(X|\theta) = \ln \sum_Z p(X, Z|\theta)$$

一般而言， $\ln p(X|\theta)$ 的形式是无法直接求解的，而联合分布 $p(X, Z|\theta)$ 可能形式上更好看，比如属于指数族分布，但由于求和符号在求对数内部，这样计算时仍然会无从下手，于是我们的EM算法就要派上用场了。

首先我们来定性地理解一下， $\{X, Z\}$ 可以称作完整数据集，但这个完整数据集我们是无法直接获取的，因为 Z 是潜在变量。那么我们可以试试从 Z 的后验分布下手，因为 $p(Z|X, \theta) \propto p(X, Z|\theta)$ ，所以这个后验分布的形式往往也是简单的，然后我们就考虑联合分布的对数似然在这个后验分布下的期望，其实就是E step：

$$Q(\theta, \theta^{\text{旧}}) = \sum_Z p(Z|X, \theta^{\text{旧}}) \ln p(X, Z|\theta)$$

在M step中我们就去最大化这个期望。这里区分 $\theta, \theta^{\text{旧}}$ ，是因为后验分布是根据旧的参数算出来的，在进行M step时，它已经被固定了。

所以我们就已经能写出EM算法的流程了：

1. 为参数设置一个初始值 $\theta^{\text{旧}}$
2. E step: 计算 $p(Z|X, \theta^{\text{旧}})$ ，得到 $Q(\theta, \theta^{\text{旧}})$
3. M step: $\theta^{\text{新}} = \arg \max_{\theta} Q(\theta, \theta^{\text{旧}})$
4. 检查是否收敛，否则回到2

一言以蔽之，EM算法就是计算联合分布对数似然在潜在变量的条件分布下的期望，然后求极大，反复迭代达到收敛，最终求得观测变量似然函数的极大值

理论证明

上面只是我们定性的理解，下面我们来做一个定量的证明，为什么EM算法能够收敛
取关于Z的任一分布 $q(Z)$ ，对于任意的 q ，我们都有以下式子成立：

$$\ln p(X|\theta) = L(q, \theta) + KL(q||p)$$

其中，

$$L(q, \theta) = \sum_Z q(Z) \ln \frac{p(X, Z|\theta)}{q(Z)}, KL(q||p) = - \sum_Z q(Z) \ln \frac{p(Z|X, \theta)}{q(Z)}$$

很容易验证上述等式的成立。

我们可以发现， $KL(q||p)$ 刚好是KL散度的形式，于是有 $KL(q||p) \geq 0$ ，当且仅当 $q(Z) = p(Z|X, \theta)$ 时等号成立。因此，

$$L(q, \theta) \leq \ln p(X|\theta)$$

也就是说， $L(q, \theta)$ 是 $\ln p(X|\theta)$ 的下界。

于是，对于 $\ln p(X|\theta)$ 的最大化我们可以分成两个步骤：

- **E step**

可以看到， $\ln p(X|\theta)$ 的表达式是与 q 无关的，所以为了提升下界 $L(q, \theta)$ ，我们可以减小 $KL(q||p)$ ，注意，在这一步 $\ln p(X|\theta)$ 是不变的。显然，当 $q(Z) = p(Z|X, \theta)$ 时，KL散度最小，也就是 $L(q, \theta)$ 取最大。可以发现，我们选择的 $q(Z)$ 正是上一节中提到Z的后验分布

- **M step**

这一步我们固定已经选好的 $q(Z)$ ，再对 $L(q, \theta)$ 做最大化，这一步会使 $L(q, \theta)$ 继续增大，同时 $KL(q||p)$ 只会增大而不会减小。因此， $\ln p(X|\theta)$ 一定会增大。

我们来观察一下此时 $L(q, \theta)$ 的形式，

$$L(q, \theta) = \sum_Z q(Z) \ln \frac{p(X, Z|\theta)}{q(Z)} = \sum_Z p(Z|X, \theta) \ln p(X, Z|\theta) + const$$

这不正是我们前面提到的Q函数吗！

这样，我们就已经证明EM算法的收敛性。

其实还有一种从Jensen不等式出发来进行证明的角度，这里就不细说了，大致就是从

$$\ln \sum_Z p(X, Z|\theta) = \ln \sum_Z \frac{q(Z)}{q(Z)} p(X, Z|\theta) \geq \sum_Z q(Z) \ln \frac{p(X, Z|\theta)}{q(Z)}$$

开始，也能得出一样的结果

实战

EM算法的一个经典例子就是用来解高斯混合模型，很多参考书上都有，我就不写了（因为马上要和人去打球，懒得写了hhhh）

—— 2020.9.4